OpenTuner: An Extensible Framework for Program Autotuning

Hauptseminar WS 2016/2017

Matthias Tietz

10.02.2017

Gliederung

1. Einleitung

- Suche nach optimaler Programm-Implementierung teil-/vollautomatisierbar
- bestehende Autotuning-Frameworks meist domänenspezifisch (ATLAS, FFTW)

OpenTuner:

- Ausdrücken des Suchraums statt direkter Optimierung
- Verfahren komfortabler und oft effizienter (große Suchräume)
- mehrere Optimierungsziele komibinierbar
- stark auf Erweiterbarkeit ausgelegt

gebräuchliche Begriffe:

- **Parameter**: Variablen eines bestimmten Typs
- **Konfiguration**: konkrete Zuweisungen von Parametern
- **Konfigurations-Manipulator**: Bearbeiten der Parametern in Konfig.

- **Suchraum**: zu durchsuchende Menge von Konfigurationen
- **Suchtechnik**: Suchraum erforschen (KM), Anfragen für Messung (Ergebnis)
- **Suchprozess**: Lesen/Schreiben von Konfigurationen

- **Messprozess**: konkrete Konfiguration ausführen
- **Messresultat**: Ergebnis der Messung, abhängig von Optimierungsziel(en)
- **Ergebnisdatenbank**: Festhalten aller Ergebnisse während Tuning-Vorgangs

Die Herausforderungen bei der Entwicklung eins Autotuning-Frameworks:

- 1. Eine passende Konfigurations-Repräsentation
  - Darstellung der domänenspezif. Datenstrukturen und Bedingungen
  - Qualität der Repräsentation entscheidend für Effizienz des Autotuners
- 2. Größe des gültigen Konfigurations-Raumes
  - Kürzen des Konfigurations-Raumes $\rightarrow$ Verlieren guter Lösungen (bei bisherigen Autotunern gängige Praxis, da vollständige Suche)
  - rießige Konfigurationsräume möglich $\rightarrow$ intelligente Suchtechniken notwendig
- 3. Beschaffenheit des Konfigurations-Raumes
  - Suchräume in der Praxis meist sehr komplex
  - domänenspezif. Suchtechniken notwendig um optimale Lösung effizient zu ermitteln

2. OpenTuner Framework

- Autotuning-Problem $\rightarrow$ Suchproblem
- Suchraum: Menge der Konfigurationen (Belegung von Parametern)
- Messung: 1 konkrete Konfig. wird gemessen: Ausführung $\rightarrow$ Ergebnis
- Möglichkeit mehrere Messungen parallel auszuführen

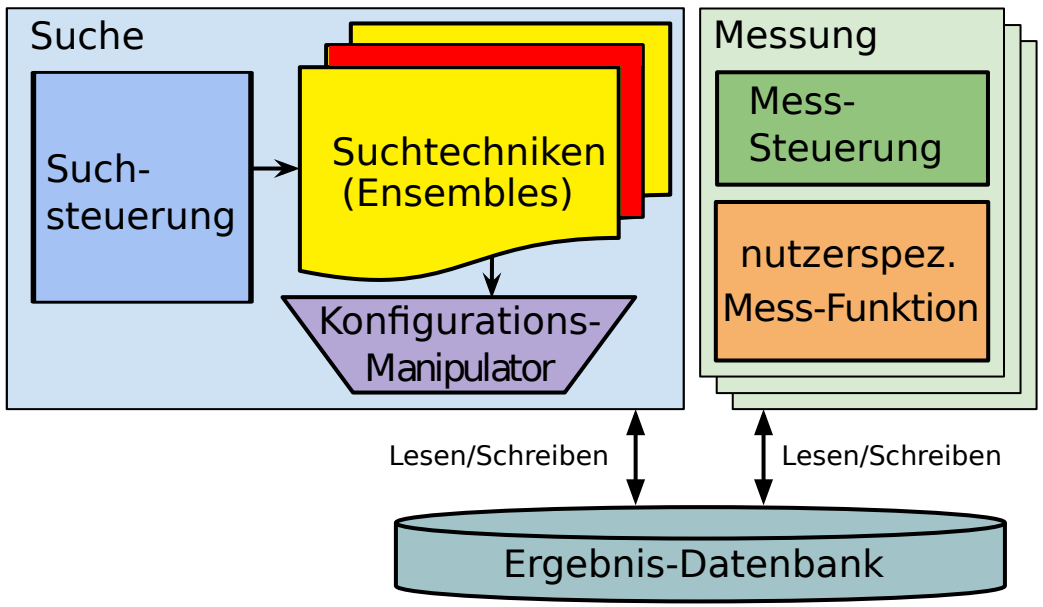

Verwendung

- 1. Suchraum definieren (Konfig.-Manipulator)
- 2. `run()`-Methode definieren: Auswerten der Konfig. im Suchraum $\rightarrow$ Ergebnis
- 3. Festlegen des Optimierungsziels
- Umsetzung mittels kleinem Python-Programm (OpenTuner API), Framework ist ausschließlich in Python geschrieben

Suchtechniken

- OpenTuner stellt Suchtechniken für viele Suchraum-Typen bereit
- Ausführen mehrerer Suchtechniken gleichzeitig (Ensembles)
- dynamische Testzuweisung anhand Erfolges dieser Techniken

Konfigurations-Manipulator

- Abstraktionsschicht zwischen Suchtechnik und roher Konfigurations-Struktur
- Liste der Parameter/Datenstruktur ist dynamisch erweiterbar

Parameter-Typen

- jeder Parametertyp ist verantwortlich für Schnittstelle zwischen roher Parameterrepräsentation und stand. Ansicht dieses Parameters für die Suchtechnik
- Parameterrepräsentation und Abstraktion erweiterbar/konfigurierbar

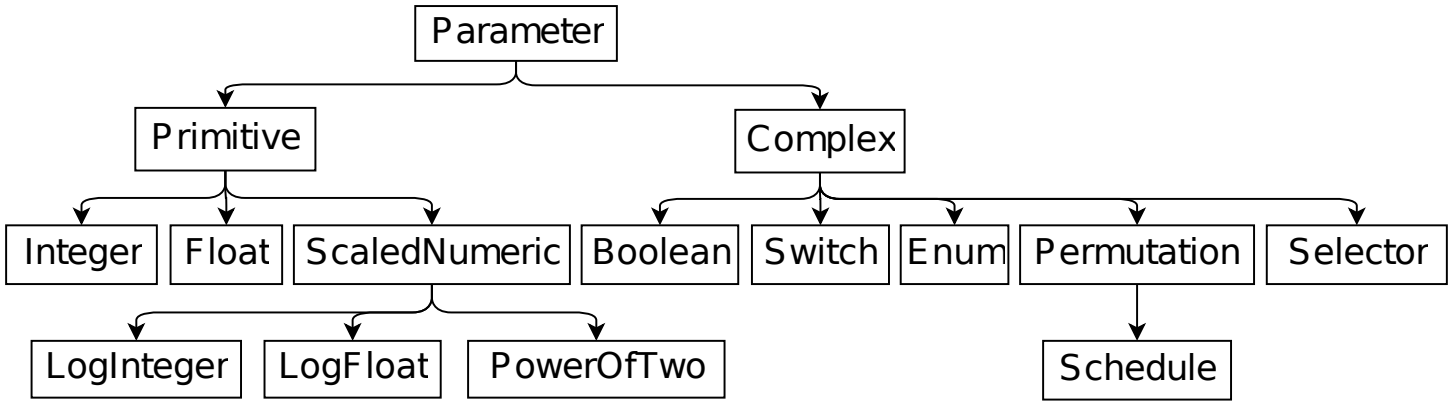

Primitive Parameter

- numerische Werte mit Unter-/Obergrenze
- `Float` und `LogFloat (-Int)` gleiche Repräsentation in der Konfiguration, aber untersch. Ansicht des zugrundeliegenden Wertes für die Suchtechnik (skaliert)
- Grund: ohne Logskal. würde Effekt der Wertänderung mit steigender Parametergröße sinken

Komplexe Parameter

- haben variables Set an Manipulatoren $\rightarrow$ stochastische Parameter-Änderungen
- einfach domänenspezif. Strukturen zum Suchraum hinzuzufügen
- `Boolean, Switch` und `Enum` bewusst als komplex. Parameter, Darstellung als ungeordnete Sammlung $\rightarrow$ es existiert kein Gradient (wie bei prim. Parm.)
- `Permutation` : Liste von Werte inkl. Manipulatoren zur randomisierten Änderung der Reihenfolge
- `Schedule` ist Sonderfall von `Permutation` : topolog. Sortierung nach jeder Änderung
- `Selector`

Parameter-Interaktion

- Zusätzlich existieren erweiterbare Methoden für die Suchtechniken um zwischen mehreren Parametern zu interagieren. (z.B. Differenz-Funktion)

Optimierungsziele

- OpenTuner unterstützt mehrere Ziele, standardmäßig wird nach der `Zeit` optimiert
- `Genauigkeit`, `Energie`, `Größe` oder ein nutzerdef. Ziel
- Es können auch mehrere Ziele zugleich verfolgt werden, bspw. `Genauigkeit einhalten, gleichzeitig Zeit minimieren`

3. Existierende Anwendungen der Entwickler

a) GCC/G++ Flags

- klassische Parameter-Optimierung
- unterstützte Flags: `g++ --help=optimizers`
- Parameter inkl. zulässiger Wertebereiche: `params.def` (gcc source code)
- Implementierung des Autotuners:
  - 1. Erstellen des `configuration manipulator` : Menge der Parameter (Suchraum) *Optimierungslevel, GXX-Flags/-Parameter*
  - 2. Erstellen der `run`-Funktion
  - 3. Festlegen des Optimierungsziels

```
import opentuner                                                    1
from opentuner import ConfigurationManipulator                      2
from opentuner import EnumParameter                                 3
from opentuner import IntegerParameter                              4
from opentuner import MeasurementInterface                          5
from opentuner import Result                                        6
                                                                    7
GCC_FLAGS = [                                                       8
  'align-functions', 'align-jumps', 'align-labels',                 9
  'branch-count-reg', 'branch-probabilities',                       10
  # ... (176 total)                                                 11
]                                                                   12
                                                                    13
# (name, min, max)                                                  14
GCC_PARAMS = [                                                      15
  ('early-inlining-insns', 0, 1000),                                16
  ('gcse-cost-distance-ratio', 0, 100),                             17
  # ... (145 total)                                                 18
]                                                                   19
```

```
class GccFlagsTuner(MeasurementInterface):

  def manipulator(self):
    """
    Define the search space by creating a
    ConfigurationManipulator
    """
    manipulator = ConfigurationManipulator()
    manipulator.add_parameter(
      IntegerParameter('opt_level', 0, 3))
    for flag in GCC_FLAGS:
      manipulator.add_parameter(
        EnumParameter(flag,
                      ['on', 'off', 'default']))
    for param, min, max in GCC_PARAMS:
      manipulator.add_parameter(
        IntegerParameter(param, min, max))
    return manipulator
```

```
  def run(self, desired_result, input, limit):
    """
    Compile and run a given configuration then
    return performance
    """
    cfg = desired_result.configuration.data
    gcc_cmd = 'g++ raytracer.cpp -o ./tmp.bin'
    gcc_cmd += ' -O{0}'.format(cfg['opt_level'])
    for flag in GCC_FLAGS:
      if cfg[flag] == 'on':
        gcc_cmd += ' -f{0}'.format(flag)
      elif cfg[flag] == 'off':
        gcc_cmd += ' -fno-{0}'.format(flag)
    for param, min, max in GCC_PARAMS:
      gcc_cmd += ' --param {0}={1}'.format(
        param, cfg[param])

    compile_result = self.call_program(gcc_cmd)
    assert compile_result['returncode'] == 0
    run_result = self.call_program('./tmp.bin')
    assert run_result['returncode'] == 0
    return Result(time=run_result['time'])

if __name__ == '__main__':
  argparser = opentuner.default_argparser()
  GccFlagsTuner.main(argparser.parse_args())
```

Konkrete Anwendungen der Entwickler

- die Methode `run` implementiert die Messfunktion der Konfigurationen
- Konfiguration: spez. GXX-Befehlszeile (Opt, Flags, Params)
- Ausführen der Befehlszeile $\rightarrow$ Executable erstellen
- `call_program` : Ausführen und Messen des Programms
- `Ergebnis` wird erstellt und in Datenbank geschrieben (record type abhängig von Optimierungsziel)

- vergleichbare Anwendung: Halide, PetaBricks, Stencil

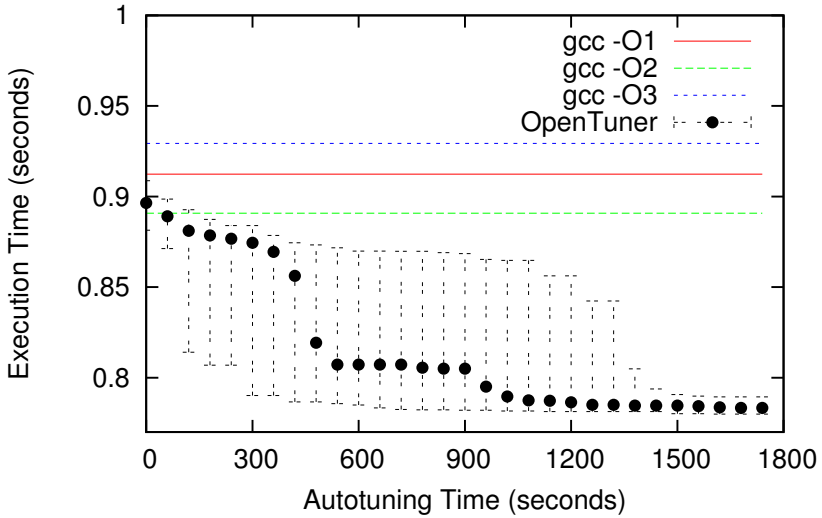

(a) fft.c

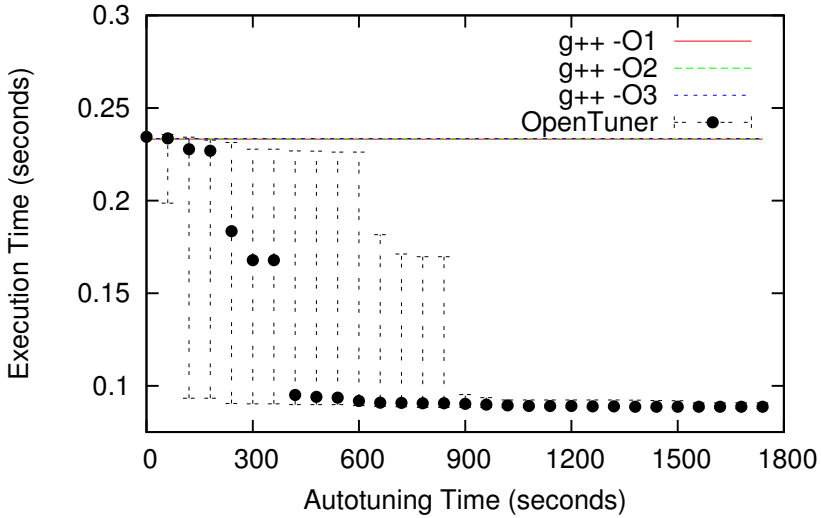

(b) matrixmultiply.cpp

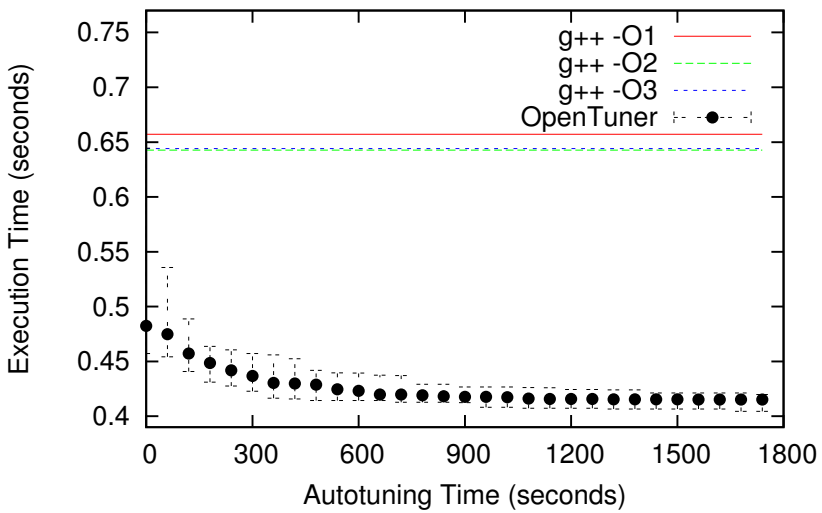

(c) raytracer.cpp

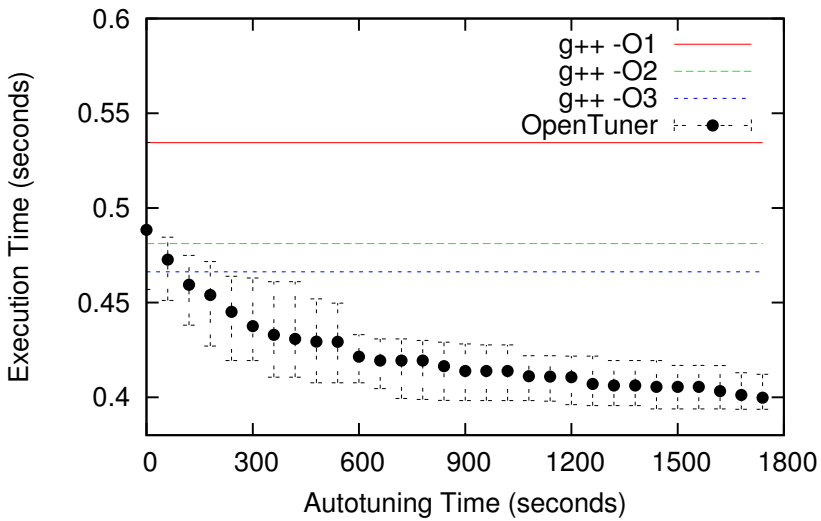

(d) tsp_ga.cpp

b) Unitary Matrices

- Synthetisierung von Matrizen in optimaler Zeit
- **bisher** traditioneller Autotuner zur Programmoptimierung
- **hier** Suche als Subroutine zur Laufzeit
- das Problem hat fixes Set von Operatoren (Controls), repräsentiert als Matrizen
- Ziel: Finden einer Sequenz von Operatoren, sodass Matrixmultiplikation die Zielmatrix ergibt
- Zielfunktion: Abstand (Genauigkeitswert) des Produktes der aktuellen Sequenz zum Ziel (trace fidelity)

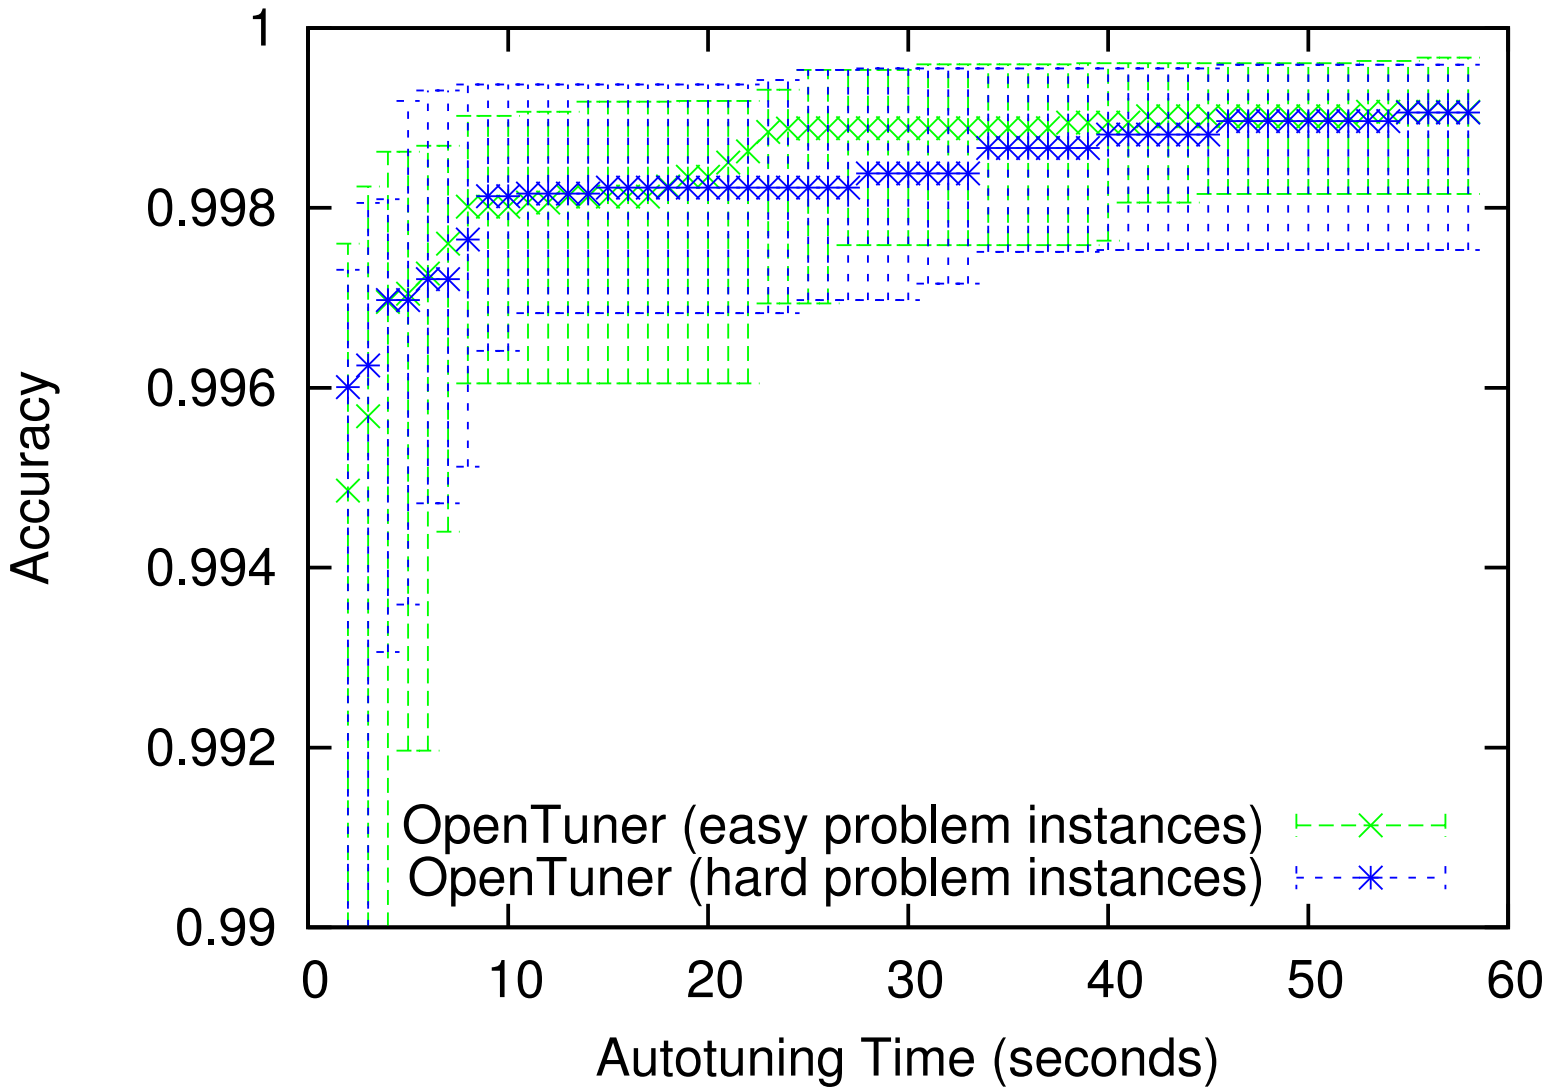
1
0.998
0.996
0.994
0.992
0.99
Accuracy
0
10
20
30
40
50
60
Autotuning Time (seconds)
OpenTuner (easy problem instances)
OpenTuner (hard problem instances)

c) Super Mario

- Abschließen des ersten Levels durch Sequenz von Button-Eingaben
-

- abc abc abc

Quellen

- abc abc abc