

OpenTuner: An Extensible Framework for Program Autotuning Hauptseminar - Bachelor Informatik Matthias Tietz

# OpenTuner: An Extensible Framework for Program Autotuning

Matthias Tietz

Hauptseminar Bachelor Informatik

10.01.2017



OpenTuner: An Extensible Framework for Program Autotuning Hauptseminar - Bachelor Informatik Gliederung

- 1. Einleitung
- 2. OpenTuner Framework
- 3. Anwendungsbeispiele
- 4. Aktueller Stand
- 5. Zusammenfassung



- 1. Einleitung
- 2. OpenTuner Framework
- 3. Anwendungsbeispiele
- 4. Aktueller Stand
- 5. Zusammenfassung

# **Paper**

- OpenTuner: An Extensible Framework for Program Autotuning
- Jason Ansel, Shoaib Kamil, Kalyan Veeramachaneni, Jonathan Ragan-Kelley, Jeffrey Bosboom, Una-May O'Reilly, Saman Amarasinghe (MIT 2014)

#### Motivation

- ► Tuning-Prozess: automatisierbar, effizient?
- bestehende Autotuning-Frameworks domänenspezifisch (ATLAS, FFTW)

# OpenTuner:

- komfortables Optimierungsverfahren
- mehrere Optimierungsziele kombinierbar, hohe Erweiterbarkeit
- Performance-Portabilität



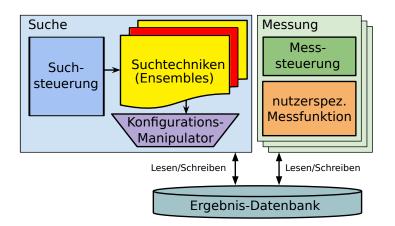
# Wichtige Begriffe:

- ► Parameter: Variable eines bestimmten Typs
- ► Konfiguration: konkrete Wert-Zuweisung (Parameter)
- Konfigurations-Manipulator: Bearbeiten der Parameter
- ► Suchraum: zu durchsuchende Menge von Konfigurationen
- ► Suchtechnik: Suchraum erforschen, Anfragen für Messung
- ▶ Messresultat: Ergebnis der Messung, abhängig von Optimierungsziel(en)
- ► Ergebnisdatenbank: Festhalten aller Ergebnisse des Tuning-Vorgangs

# Herausforderungen bei der Entwicklung eines Autotuning-Frameworks:

- 1. Eine passende Konfigurations-Repräsentation
  - Darstellung der Datenstrukturen und Bedingungen
  - entscheidend für Effizienz des Autotuners
- 2. Größe des gültigen Suchraumes
  - ightharpoonup rießige Konfigurationsräume möglich ightarrow intelligente Suchtechniken
  - ► Kürzen des Suchraumes → Verlieren guter Lösungen
- 3. Beschaffenheit des Suchraumes
  - Suchräume in der Praxis meist sehr komplex
  - domänenspezifische Suchtechniken notwendig

- 1. Einleitung
- 2. OpenTuner Framework
- 3. Anwendungsbeispiele
- 4. Aktueller Stand
- 5. Zusammenfassung



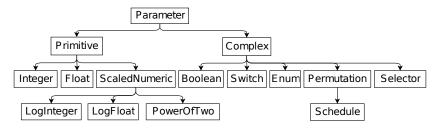
# Verwendung

- 1. Suchraum definieren
- 2. run()-Methode definieren: Auswerten der Konfiguration  $\rightarrow$  Ergebnis
- 3. Festlegen des Optimierungsziels
- Umsetzung: Python-Programm (OpenTuner API)

#### Suchtechniken

- OpenTuner stellt grundlegende Suchtechniken bereit
- Ausführen mehrerer Suchtechniken (Ensembles)
- Austausch von Ergebnissen über Datenbank
- dynamische Testzuweisung anhand Erfolg der Suchtechniken

#### Parameter-Arten



#### **Primitive Parameter**

- numerische Werte mit Unter-/Obergrenze
- Float und LogFloat (-Int) gleiche Repräsentation, Werte skaliert

# **Komplexe Parameter**

- Permutation: Liste von Werten inkl. Reihenfolge-Manipulator
- Schedule, Selector

# **Optimierungsziele**

- OpenTuner unterstützt mehrere Ziele, default: time
- accuracy, energy, size, confidence oder ein nutzerdef. Ziel
- ► Ziel-Kombination: time-accuracy

- 1. Einleitung
- 2. OpenTuner Framework
- 3. Anwendungsbeispiele
- 4. Aktueller Stand
- 5. Zusammenfassung

## GCC/G++ Flags

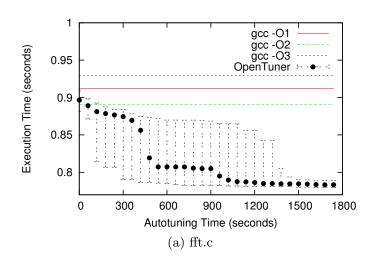
- klassischer Parameter-Autotuner
- ▶ unterstützte Flags: g++ --help=optimizers
- ► Parameter inkl. zulässiger Wertebereiche: params.def (gcc source code)
- Zielprogramme zur Laufzeit-Optimierung:
  - fft.c-Schnelle Fourier-Transformation
  - matrixmultiply.cpp-Matrix-Multiplikation

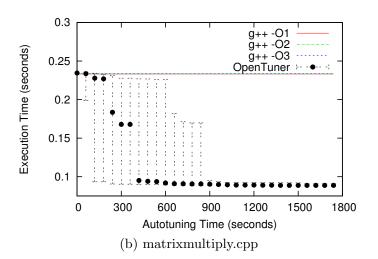
```
import opentuner
from opentuner import ConfigurationManipulator
from opentuner import EnumParameter
from opentuner import IntegerParameter
from opentuner import MeasurementInterface
from opentuner import Result
GCC FLAGS = [
  'align-functions', 'align-jumps', 'align-labels',
  'branch-count-reg', 'branch-probabilities',
 # ... (176 total)
# (name, min, max)
GCC PARAMS = [
  ('early-inlining-insns', 0, 1000),
  ('gcse-cost-distance-ratio', 0, 100),
 # ... (145 total)
```

```
class GccFlagsTuner(MeasurementInterface):
 def manipulator(self):
   11 11 11
   Define the search space by creating a
   ConfigurationManipulator
   manipulator = ConfigurationManipulator()
   manipulator.add_parameter(
     IntegerParameter('opt_level', 0, 3))
   for flag in GCC_FLAGS:
     manipulator.add_parameter(
       EnumParameter(flag,
                    ['on', 'off', 'default']))
   for param, min, max in GCC_PARAMS:
     manipulator.add_parameter(
       IntegerParameter(param, min, max))
   return manipulator
```

イロト イ部ト イミト イミト

```
def run(self, desired_result, input, limit):
  0.00
 Compile and run a given configuration then
 return performance
 cfg = desired_result.configuration.data
 gcc_cmd = 'g++ raytracer.cpp -o ./tmp.bin'
 gcc_cmd += ' -0{0}'.format(cfg['opt_level'])
 for flag in GCC_FLAGS:
   if cfg[flag] == 'on':
     gcc_cmd += ' -f{0}'.format(flag)
   elif cfg[flag] == 'off':
     gcc_cmd += ' -fno-{0}'.format(flag)
 for param, min, max in GCC_PARAMS:
   gcc_cmd += ' --param {0}={1}'.format(
     param, cfg[param])
 compile_result = self.call_program(gcc_cmd)
 assert compile_result['returncode'] == 0
 run_result = self.call_program('./tmp.bin')
 assert run_result['returncode'] == 0
 return Result(time=run result['time'])
```

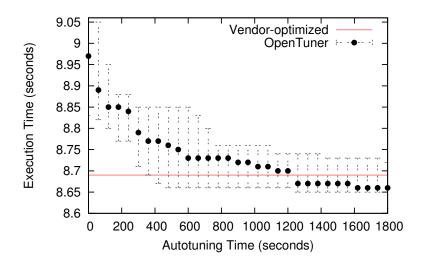






# **High Performance Linpack Benchmark (HPL)**

- ▶ Bestimmen der floating point performance von Computern
- Kriterium für Wahl der Top 500 Supercomputer
- HPL misst Geschwindigkeit für Lösen großer LGS
- ca. 15 verschiedene Parameter
- größter Performance-Einfluss: Matrix-Blockgröße
- HPL besitzt eingebauten Autotuner (vollst. Suche)
- OpenTuner im Vergleich zu HPL-Implementierung von Intel



# Ähnliche Anwendungen des Frameworks

#### Halide

- Sprache und Compiler für Bildverarbeitung
- Ausführungsreihenfolge in Grafik-Pipeline
- ► Pipeline-Schedule bestimmt die Performance

#### **PetaBricks**

- ► Kombination versch. Algorithmen (algorithmic selectors)
- ▶ block sizes, thread counts, iteration counts...

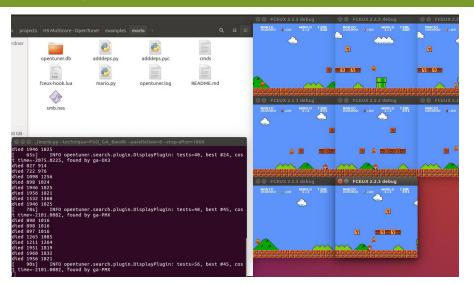
## **Super Mario**

- Absolvieren des ersten Levels: Sequenz von Tasten-Eingaben (Konfig.)
- lacktriangle Tasten-Eingaben ightarrow Speichern in Datei ightarrow Abspielen in NES-Emulator
- Wiedergabe in Emulator schneller als in Echtzeit
- Auswerten mehrerer Instanzen des Emulators parallel
- 7iel: Maximieren der #Pixel die Mario nach rechts läuft.
- Suchraum: horizontale Bewegung nach rechts
- Eingaben-Modellierung:
  - welche Taste
  - zu welchem Zeitpunkt (Frame)
  - wie lange gedrückt wird





## Anwendungsbeispiele Super Mario



**Abbildung: Tuning-Prozess** 



```
☐ ./mario.py --technique=PSO_GA_Bandit --parallelism=8 --stop-after=1800
died 2763 2360
died 2588 2149
died 2763 2360
died 2763 2360
             INFO opentuner.search.plugin.DisplayPlugin: tests=96, best #75, cos
    168s]
t time=-3234.8174, found by ga-0X1
died 898 1016
died 1215 1262
died 1558 1538
died 2009 1931
died 2009 1931
died 2763 2360
died 1764 1766
won 3161 2356
             INFO opentuner.search.plugin.DisplayPlugin: tests=104, best #101, c
ost time=-4241.0531, found by ga-0X3
died 296 536
died 704 757
died 826 912
died 898 1016
died 1522 1379
died 1492 1612
died 1765 1765
won 3161 2453
```

Abbildung: Ziel erreicht

Demo: Erstes Level in Super Mario

- 1. Einleitung
- 2. OpenTuner Framework
- 3. Anwendungsbeispiele
- 4. Aktueller Stand
- 5. Zusammenfassung

- www.github.com/jansel/opentuner
- MIT-Lizenz
- Entwicklung 2014-2015
- Erweiterung durch Nutzer
- gute Dokumentation
- Ziel: Einsatz in bestehenden und neuen Domänen

- 1. Einleitung
- 2. OpenTuner Framework
- 3. Anwendungsbeispiele
- 4. Aktueller Stand
- 5. Zusammenfassung

#### **PRO**

- Flexibilität und Erweiterbarkeit
- einfache und klare Handhabung
- viele Beispielanwendungen
- mehrere Optimierungsziele (Kombination)
- bessere Ergebnisse als bisherige Autotuner

#### **CONTRA**

- Optimierungsgrad variiert stark
- ► Trade-off: Zeitaufwand ↔ Nutzen

## Quellen



Shoaib Kamil. *Hands on session*. Programming Language Design and Implementation 2015

www.github.com/jansel/opentuner(08.01.2017)

www.opentuner.org (05.12.2016)